

昇腾AI处理器

从战略抉择到技术引领的发展之路

谈谈你对 昇腾 NPU 的理解



发布时间

什么时候发布？



芯片类型

有哪些系列？



核心架构

采用什么架构？



算力规模

有多大算力？



昇腾来时路：核心技术无外援，自主创新谋自强

申请遭拒



华为曾向友商申请提出
将相关技术授权给华为，**当场被拒**

彻底清醒



何庭波 - “华为芯片女王”
“核心技术，求不来、要不到、更等不起”

自主创新



廖恒 - 华为 Fellow
创新性提出**3D Cube达芬奇架构**

达芬奇架构：为AI计算而生，将AI计算效率做到极致


GPU 兼顾图像渲染与AI计算，Cube单元占比低

V100 - Volta架构 (2017)



Cube计算单元占比约
87.4%

Cube = $4 \times 4 \times 4$
单时钟周期完成
64 次运算




A100 - Ampere架构 (2020)




Cube计算单元占比约
93.7%

Cube = $8 \times 8 \times 4$
单时钟周期完成
256 次运算



昇腾NPU 专为AI计算设计，Cube占比高，极致面效比

昇腾NPU - 达芬奇架构 (2018)



Cube计算单元占比约
99.2%


Cube = $16 \times 16 \times N$
 $N = 1/2/4/8/16$

单时钟周期最大可完成
4096 次运算

计算单元做成三维立体结构直接完成矩阵运算，与传统2D结构不同，3D Cube只需 $16 \times 16 \times 16$ 立体结构，一个Cycle完成全部计算

设计原则：不追求最小面积、不追求功耗极致，聚焦单位功耗下AI算力最大化

达芬奇基本架构：矩阵乘Cube、向量运算Vector、标量运算Scalar Unit



Cube (矩阵乘, 算力担当)

- **Cube**: 矩阵乘运算单元, 一拍完成一个fp16的 16x16与16x16矩阵乘; $C = A * B$; 如果是int8输入,则一拍完成 16*32 与 32*16 矩阵乘
- **accumulator**: 累加器, 把当前矩阵乘的结果与前次计算的中间结果相加, 可以用于完成卷积中加bias操作; $C = A * B + C$
- **L0A/L0B/L0C Buffer**: L0A 存储矩阵乘的左矩阵数据, L0B 存储矩阵乘的右矩阵数据, L0C 存储矩阵乘的结果和中间结果

Vector (向量运算, 多面手)

- **Vector Unit**: 向量运算单元, 覆盖各种基本的计算类型和许多定制的计算类型, 主要包括FP16/FP32/int32/Int8等数据类型的计算
- 一拍可以完成两个128长度fp16类型的向量相加/乘, 或者64个fp32/int32类型的向量相加/乘
- **Unified Buffer(UB)**: 保存Vector运算的源操作数和目的操作数; 一般要求32Byte对齐;

Scalar Unit (标量运算, 司令部)

- **Scalar Unit**: 负责完成AICore中的标量运算, 功能上可以看做一个小CPU, 完成整个程序的循环控制、分支判断、CUBE/Vector等指令的地址和参数计算以及基本的算术运算等
- **GPR**: 通用寄存器, 目前包含32个通用寄存器
- **SPR**: 专用寄存器, 为了支持指令集一些指令的特殊需要, Davinci设计了许多专用寄存器

昇腾发布首款训、推芯片，统一架构的算力底座，构建端 - 边 - 云全场景AI

昇腾品牌命名：何庭波提议用中文“昇腾”，取自“日升月腾”，寓意积极向上、不断突破

昇腾310 推理芯片




2018年9月，HC大会

昇腾910 训练芯片




2019年9月，HC大会




昇腾310处理器：架构特性与典型应用场景

◆ 目标场景是**边缘推理**，如**智慧城市、智慧新零售、机器人、工业制造**等，其架构包含 Davinci Core、DVPP、LPDDR4等



基于华为自研达芬奇架构，工艺7纳米

- 支持**22/16/8** TOPS INT8三级算力
- 内置DVPP预处理单元，支持**20路**高清视频实时分析（1080P 25FPS）
- 显存容量及带宽16/32G@240GB/s
- 典型功耗仅**6.5W**
- 内存支持LPDDR4X，总带宽51.2 GB/s
- 支持**H.264**和**H.265**编解码



- 相比昇腾910，昇腾310的**定制化IP**相对较少，但是提供了**更多外设接口**。由于在边缘推理场景下batch size通常只有1，因此昇腾310选择了**较小的矩阵计算维度**($m = 4, n = 16, k = 16$)以实现 $Cmn=Amk \times Bkn$

昇腾910处理器：架构特性与典型应用场景


◆ 采用了芯粒 (chiplet) 技术，包含六个die：

1个计算芯粒(含32个Davinci Core、16个CPU Core和4个 DVDP)，1个IO芯粒，和4个HBM芯粒(总计 1.2TB/s 带宽)



基于华为自研达芬奇架构，工艺7纳米

- 支持320/280/220 FP16三级算力
- HBM容量与带宽 32GB@1.2TB/s
- 支持16 channel 4K (或64 channel 1080P) 60 FPS H.264/H.265编解码
- 功耗最大300W
- 集成32个华为达芬奇AI Core + 16个 TaiShan核+ 1 * 100GE RoCEv2网卡
- 出口总带宽56.5 Gb/s



1. **高算力:** 训练场景通常使用的Batch Size较大，因此采用最高规格的 Ascend-Max，每个 Core 每个周期可以完成 $16 \times 16 \times 16 = 4096$ 次 FP16 乘累加。
2. **高带宽:** 训练场景下计算反向SGD时，会有大量对Last Level Cache和片外缓存的访问，需要配备较高的 Load/Store 带宽，因此昇腾910除了DDR还采用了HBM技术


主打大模型与基础模型训练，也支持训推一体、大模型推理，多用于智算中心、科研与高校算力平台、公有云/私有云AI算力服务等

Transformer走入大众视野，大模型预训练成为行业热点，智算中心规模化建设

模型参数量从亿级向千亿级的突破

AI集群是业界AI模型开发的共同选择

模态支持从单一模态的单一任务发展为多种模态的多种任务



- BERT (2018) : Transformer 在学术界、工业界技术范式全面流行
- GPT-3 (2020) : 证明 Transformer 堆规模可行，开启大模型产业浪潮
- ChatGPT (2022) : Transformer 大模型走入大众视野，全社会爆火



昇腾910B处理器：强化算力显存，支撑大模型预训练

为了满足客户的需求，昇腾NPU需要：①**提供更高的算力**，能够加速各种复杂的模型任务；②**提供更大的memory容量**，单device能够缓存更多的模型参数，减少跨device访问的开销；③**提供更大的互联带宽**，保证尽快实现跨device的数据通信




昇腾910B (2023Q1)

- 算力：400T@FP16
- HBM容量与带宽：64GB@1.2TB/s
- 互联带宽：392GB/s

昇腾910B采用第二代 Davinci AI Core

第一代


Cube与Vector耦合架构



AI Core


第二代

Cube与Vector解耦架构




基本粒度：AI Cluster (AIC + 2 AIV)

昇腾910B架构示意图




- AI计算单元部分包含**25个**AI Cluster，每个AI Cluster包含**1个**AIC和**2个**AIV，即NPU总共包含**25个**AIC和**50个**AIV
- Memory系统包含4个HBM2E提供**64GB**的内存容量，L2 cache提供192MB的超大缓存
- 2个CPU Cluster，每个Cluster包含4个AICPU，即NPU总共包含8个AICPU
- 4个DVPP Cluster，STARS调度器，DSA专用加速器，SDMA/RDMA，I/O互联子系统

昇腾910B处理器：Cube与Vector计算单元架构设计



AIC主要完成矩阵乘和累加操作，在各种应用场景的卷积、GEMM等任务中发挥关键作用

- 支持FP32/FP16/HF32/BF16/INT8/INT4等数据类型，可满足训练和推理等各种场景的需要；
- **新增BF16/HF32计算类型**，能够获得比FP32更快的处理速度，同时保证模型精度满足要求
- 支持推理场景在不损失精度的前提下，深度学习模型能够**获得两倍的性能加速**




AIV是辅助Cube计算的单元，实现各种形式的标量计算和向量运算


- **Vector算力翻倍**，提高Vector和Cube的算力配比，使主流模型的性能获得进一步提升；
- 支持FP32/FP16/INT32/INT16等数据类型，实现不同精度的Vector计算；
- 在Region Proposal network、推荐系统、Sort排序等典型场景做了针对性的指令增强和指令增添；

千亿大模型、MoE模型成为主流，智算集群的训练性能面临“木桶效应”

模型参数变大，从单卡→单机→集群网络通信量暴增




内存、总线及网络的能力增长，远远不及算力的增长



超节点架构：突破集群物理瓶颈，引领下一代AI集群技术标准

传统节点架构


节点服务器通过网络设备互联



- 节点内FullMesh互联，点到点56GB/s
- 节点间通过200Gbps RoCE组网

超节点架构

多颗NPU通过大带宽总线互联形成一个逻辑上的超节点




超节点域内**总线高速互联**，NPU点到点**互联带宽784GB/s**
实现全局内存统一编址、统一通信协议

集群与超节点都是大算力的实现方式，但扩展方式和核心逻辑具有本质区别

对比维度	集群 (Cluster)	超节点 (Supernode)
核心逻辑	协同工作：多台独立的服务器通过网络连接，由软件统一调度，共同完成任务。 “将多台计算机连起来干活”	融为一体：通过高速互联和架构重构，将成千上万颗芯片整合成一个逻辑上单一的、强大的计算系统。 “让多台计算机变成一台计算机去干活”
扩展方式	Scale Out，向外扩展，也叫横向扩展，通过增加节点的数量。	Scale Up，向上扩展，也叫纵向扩展，增加单节点的资源数量。
通信方式	“寄快递” ：跨服务器通信需经过打包、网络传输、解包等复杂流程，延迟高。	“从书架上拿书” ：实现 内存统一编址 ，任意芯片可直接访问其他芯片的内存，通信效率极高。
互联协议	依赖传统网络（如以太网、InfiniBand），协议栈开销大。	采用专用高速互联协议（如灵衢、NVLink），并且开始引入 光互联技术 突破机柜物理限制。
计算效率	存在“通信墙”，芯片间大量时间用于等待数据同步，算力利用率较低。	突破“通信墙” ，通过架构创新大幅提升算力利用率




昇腾910C处理器：采用“双芯合璧”的设计，“以面积换算力，以工程补工艺”



关键特性


- 采用“双芯合璧”的设计，其集成约530亿个晶体管，并采用Chiplet封装技术将两颗昇腾910B芯片整合在一起
- 在FP16精度下，其算力约为560至**800TFLOPS**
- HBM容量及带宽**128G@3.2TB/s**
- 互联带宽**784GB/s**
- 支持SIMD微架构
- 支持FP32/HF32/FP16/BF16/INT8等多种数据格式

昇腾384超节点：全光互联架构，构建超大规模、灵活配置、极致性能的AI集群



应用场景 万亿/十万亿MOE、超长序列、多模态等训练场景

关键特性	规格描述
形态	12 * 47U计算柜 + 4 * 47U总线设备柜
CPU	192 * 鲲鹏920高性能版
NPU	384 * 昇腾910
交换	336 * 灵衢交换芯片 + 56 * 灵衢总线设备
AI算力	半精度(FP16) 307.2PFLOPS；单精度(FP32) 76.8PFLOPS
内存	48T HBM；最大支持3072个DDR内存插槽
硬盘	最大支持384 * 2.5英寸硬盘
散热	液冷（计算柜）+ 风冷（总线设备柜）
尺寸	计算/总线设备柜：600mm（W）x1200mm（D）x 2250mm（H）
功耗	~ 716KW（计算柜54KW / 网络柜20KW）



NPU	物理节点	计算柜	灵衢总线设备	总线柜	灵衢设备端口利用率
32	4	1	7	1	66.7%
64	8	2	14	1	66.7%
128	16	4	28	2	66.7%
256	32	8	56	4	66.7%
384	48	12	56	4	100%

端口利用率高

384超节点内**无收敛**高速互联
总线端口利用率**100%**
32/64/128/256端口利用率**66.7%**

384域内支持虚拟切分

支持16/32/64/128/256/384多种虚拟切分
支持组合切分
6*64、3*128、256+128、256+2*64

可靠性设计

系统级散热设计, 光模块失效率 30% ↓
光模块**通道抗损**、沾污检测
算子重传, 光模块故障, 不影响系统运行

昇腾950处理器：匹配不同场景需求，围绕AI Core、Memory、IO三大子系统全面演进

通过5TB/s高速互联实现内存统一访问的Chiplet

Ascend 950PR



聚焦搜索推荐场景
兼顾成本与性能

- 486T@FP16, 919T@FP8
- 128GB@1.6TB/s HiBL HBM

PR: Prefill & Recommendation


Ascend 950DT



面向大模型训推全流程
高规格支撑极致加速

- 547T@FP16, 1034T@FP8
- 144GB@4TB/s HiZQ HBM

DT: Decode & Training



AI Core子系统 平衡能效与灵活

- 新增FP8/MXFP8/MXFP4等精度格式，匹配量化加速需求
- SIMD-SIMT混合编程，匹配离散稀疏访存需求
- Cube-Vector直通，消除数据搬运


Memory子系统 平衡成本与性能

- 统一内存接口支持2款自主创新的HiBL和HiZQ HBM
- 128MB全局L2 Cache，管理粒度精细至128Byte Sector，减少内存资源浪费


IO子系统 平衡带宽与扩展

- 2TB/s超大出口带宽，提升2.5倍
- 支持消息语义+内存语义内存语义、PCIe、UBoE等多种互联
- 集成CCU，硬件卸载集Core和Memory合通信，减少AI资源占用

昇腾950处理器基本架构：达芬奇架构、高集成SoC设计、多Die合封



昇腾AI芯片三年发展路线图，以“一年一代算力翻倍”的速度稳健演进



CANN持续完善架构与能力，全面开源开放，使能开发者自主创新

新组件、新特性都在GitCode开源社区上首发，让开发者第一时间获取到最新技术

能力对位CUDA，持续丰富开源开放范围

支持开发者自主的深度挖潜和自定义开发

	 NVIDIA CUDA	 CANN
GE 图引擎	TensorRT plugins & parser	GE
集合通信库	NV NCCL	HCCL
类库/模板	NV CUTLASS	Ascend C 高阶API CATLASS 算子模板库
通用编程	NV CUDA-C	Ascend C 基础API
算子加速库	NV cuDNN	Ascend AOL
编译器	NVCC	毕昇编译器
虚拟指令集	PTX	PTO
运行时	NV Runtime	Ascend Runtime
驱动	NV Driver	Ascend Driver

 开源  开放

*2025年8月5日，CANN宣布全面开源开放
昇腾950系列产品上市即开源

30+ 客户/伙伴

自主打造 **320+** 高性能算子

FAD | FARemovePadding | MoeTopkGatingDispatch...

10+ 客户/伙伴

自主创新 **10+** 高性能集合通信

pipeline | NHR | AIV | AllToAllv | Allgather...

10+ 加速引擎创新


打造多样化训推引擎

硅基流动 | 潞晨科技 | 无问芯穹 | 未来速度 | 清昂智能...

CANN易用性持续提升，跃升中国最活跃的开源项目

- **治理运营**：目前已有12家外部企业/高校参与TSC治理，5个SIG有外部主导/参与运作，累计社区会议100+，累计1500+人次参会；
- **社区贡献**：4个单位已签署企业CLA，外部（组织+个人）累计贡献贡献30+PR；

CANN实现全面开源开放，易用性持续提升



CANN社区中国开源项目活跃度排名第一

CANN社区月活4500+人
(7月当月外部贡献代码超57%)
外部累计贡献代码285万行



基于CANN构建22个行业加速库
支撑10大行业应用落地和技术创新

具身智能 (8)	电力 (3)
交通运输 (3)	信息安全 (2)
自动驾驶 (1)	石油化工 (1)
能源&材料化学 (1)	无线通信 (1)
油气 (1)	生命科学 (1)

- **社区SIG**：共32个，10个外部主导/参与

SIG	外部参与形式	参与者
blas	参与	深圳河套学院
Multimodal-AI	主导 (筹)	深圳河套学院
cannbot	参与	深圳河套学院
Biomolecule Computing	参与 (筹)	昌平实验室
asnumpy	主导	哈工大
ascendc	参与	
catlass	参与	华南理工
recipes	参与	清程极智、清昂智能

AscendBridge: <https://gitcode.com/SLAI/SLAI-AscendBridge2>

昇腾算子评测平台CANNBench：提供一套标准化、透明化、可横向对比的算子评测服务



CANNBench 昇腾算子评测基准

实现从“能写算子”到“可量化评测算子”的关键跨越
是CANN社区最活跃的项目

<https://cannbench.com/>

关键挑战

- 哪个模型写的算子更好？
- 哪个Agent生成的代码更可靠？
- 算子的稳定性与高效性究竟如何？
-

核心能力1: Leaderboard 公开排行榜

算子在统一环境、统一规则下进行评测并公布

按难度等级独立排名 (L1/L2/L3/L4)

从入门验证到极限挑战，各层次参与者皆可找到对标位置

按模型/Agent名称灵活筛选

快速定位关注对象，横向对比不同方案

按编译、精度、性能三维度拆解展示

查看总分之外，编译错误、精度不达标、性能短板一目了然



核心能力2: 多维度算子评测流

从编译正确性、精度通过率、极致性能三个维度进行审视
所有算子在同一标尺下客观比较



※HAP: Hardware-Anchored Performance, 以硬件物理约束为锚点的实测性能

核心能力3: 真实算子评测任务

内置来自真实业务场景典型需求的算子基准评测集

全量基准评测集 (50+个算子, 4个等级)



快速验证基准评测集 (16个算子, 4个等级)



昇腾经过8年发展，历经四代产品演进，已成熟规模商用服务于千行万业

20+

万卡集群建设

科大讯飞、移动、电信、OTT...

40+

模型原生训练

Seed、LongCat、百灵、Oxygen
星火、九天、星辰、可灵、书生...

200+

模型迁移适配

Seed、LongCat、Ling、DeepSeek、
Qwen、GLM、Step、Kimi、Wan...

50+


主流AI应用上线

豆包、美团、阿福、京东
可灵、视频号、小招...

华为Atlas 历经四代产品演进，芯片出货超**百万片**，超节点发货量超过**1000+套**

2018~2022

Huawei Atlas A1 Series



2023~2025

Huawei Atlas A2 Series



2025~2026

Huawei Atlas A3 Series



2026~2027

Huawei Atlas 950 Series



联合**2900+**合作伙伴，共同孵化了超过 **6700+** 个行业解决方案，已服务各行业 **5000+** 客户

教育



金融



医疗



政务



制造



AI赋能教育行业核心场景Mini社区与昇腾交流群



“AI+教育” Mini社区

昇腾交流微信群



※ Mini社区地址: <https://www.ai-for-education.com.cn>

Thank you.